DỮ LIỆU LỚN, INT4418 · NHÓM 6

Verifier-Guided Repair

Sửa chứng minh Lean 4 có kiểm chứng dưới ràng buộc chi phí và độ trễ

Giảng viên: TS. Nguyễn Kiều Linh
Đào Văn Tâm · Trần Quang Đức Dũng · Lâm Thành Trung
Nguyễn Xuân Tùng · Khamsing OUTHAIHUENG · Mekdala Nounou

Nhóm 6 nhận chứng minh lỗi từ Nhóm 5, trả chứng minh đã kiểm chứng cho Nhóm 7/8

Nhóm 5
ứng viên Lean
→
Nhóm 6
phân loại + sửa
→
Lean
kiểm chứng
→
Nhóm 7 / 8
chứng minh đúng

Mục tiêu

- Chỉ nhận bản sửa Lean chấp nhận, giữ nguyên đề
- Có trần chi phí token, đo được P95
- Tái lập và bàn giao được

Ba câu hỏi nghiên cứu

- **RQ1** Thông báo lỗi Lean có giúp sửa tốt hơn?
- **RQ2** Luật hay LLM, thử mấy lần, tốn bao nhiêu?
- **RQ3** Mở rộng ra sao khi tăng dữ liệu, worker?

Điểm nổi bật: hệ thống chạy trọn vòng, đạt 6/6 tiêu chí nghiệm thu

Nhóm đã xây dựng

- Dataset 17.031 lỗi, nhãn từ Lean thật
- Lean REPL thường trú + worker pool
- Vòng sửa: luật, LLM, kiểm toán
- Cổng Nhóm 5, đầu ra cho Nhóm 7/8

Tiêu chí nghiệm thu: 6/6

- Hold-out tách theo định lý gốc
- So sánh với retry baseline
- Vòng lặp có giới hạn rõ
- Đo biên dịch, kiểm toán, chi phí
- Log phát lại được
- Không lặp vô hạn

Toàn bộ thực nghiệm: 2,97 USD · 121 test tự động · 67 run record

Nút thắt nằm ở quy mô, lập lịch và chi phí, không ở một phép tính

63–107 s
kiểm chứng nguội 1 tệp, nạp Mathlib

10.000
ứng viên ở mức lớn nhất

~1.000
token mỗi lần LLM sửa

67
run record + log phát lại

Mục tiêu hệ thống

- Thông lượng cao, độ trễ đuôi P95 thấp trên vài worker CPU
- Chi phí token có trần cứng; kết quả tái lập được từ dữ liệu thô

Dataset 17.031 lỗi có nhãn lấy từ chính Lean, không viết tay

17.031
mẫu lỗi, dataset v1.0

3.666
định lý gốc đã kiểm chứng

1.110
lỗi tự nhiên do Mathlib đổi

94,4%
nhãn khớp loại lỗi dự kiến

Chống rò rỉ

- Chia theo định lý gốc
- 0 trùng giữa hai phía

Ba mức quy mô

- 100 ⊂ 1K ⊂ 10K mẫu
- Hold-out: 284 · 2.907

Provenance

- Nguồn MIT, checksum
- Run record mỗi lần

Mỗi bản sửa phải qua Lean và kiểm toán trước khi được chấp nhận

Parser + taxonomy → Router → Luật / LLM → Lean REPL → Kiểm toán

7 nhóm lỗi

- Cú pháp, import, định danh
- Kiểu, timeout, sorry
- Tactic thất bại, nhóm mới

Vòng lặp có giới hạn

- Tối đa k = 1 hoặc 3 lần
- 300 s mỗi mẫu
- Dừng nếu ứng viên lặp

Kiểm toán

- Lean chấp nhận
- Không sorry / axiom
- Giữ nguyên phát biểu

Demo: lỗi → phân loại → sửa → Lean kiểm tra → kiểm toán

E000880 · luật

- Thiếu import Mathlib
- R0 sửa, Lean OK
- 0 token · 73 ms

E000003 · LLM

- Lần 1: dùng sorry → bị chặn
- Lần 2: không biên dịch
- Lần 3: đúng · 4.583 token

E000197 · vòng lặp

- Chứng minh là sorry
- Lần 1 sai, lần 2 đúng
- 779 token

Cùng dữ liệu, phần cứng và seed, chỉ đổi chiến lược

Chiến lược

- Không sửa · chỉ luật
- Blind là baseline
- LLM + chẩn đoán · lai

Ma trận

- k = 0 / 1 / 3
- 100 / 1K / 10K mẫu
- 1 / 2 / 4 worker · 3 lần

Môi trường

- Kaggle 4 vCPU, 31 GB
- Lean 4.35 + Mathlib
- Gemini Flash-Lite

Tổng chi phí API cho toàn bộ thực nghiệm: $2,97

Kết quả: chẩn đoán vừa tốt hơn vừa rẻ hơn, REPL gỡ nút thắt kiểm chứng

RQ1 · Thông báo lỗi

53,9%

thành công đã kiểm toán

- Baseline 31,7%, cùng k=1
- Rẻ hơn 45%: $1,13 / 1K mẫu

RQ2 · Chiến lược

65,1%

LLM + chẩn đoán, k=3

- $2,45 / 1K mẫu
- Lai k=3: 59,5%
- Chỉ luật: 23,9%, $0

RQ3 · Mở rộng

3 ms

P50 mỗi định lý với REPL

- Chạy nguội: 63–107 s
- 10K: 1,52 → 2,86 mẫu/s
- P95 3,1 → 6,5 s, nghẽn CPU

Biểu đồ chi tiết: phụ lục P1–P3

Phân tích: luật đúng gần hoàn hảo, luật sai kéo chiến lược lai xuống

Luật	Áp dụng	Chính xác
R0 khôi phục import	99	97%
R7 ngân sách heartbeat	81	100%
R1 cân bằng ngoặc	99	27%
R3 bảng import	253	0%
R2 chèn từ khoá	126	0%

Ablation bộ phân loại

- Khớp nhãn 72,3% → 96,3%
- Token giảm 31%
- Lai k=1 lại giảm 34,9% → 30,3%
- Nút thắt: độ chính xác của luật

Không có kiểm toán, tỷ lệ thành công bị thổi phồng

75,0%

biên dịch được với LLM k=3

65,1%

thành công đã kiểm toán

17–26%

bản sửa lỗi đã đổi đề

Kiểm toán chặn

- sorry, admit, axiom, native_decide
- Thay đổi tên, giả thiết hoặc kết luận của định lý

Kết luận: chẩn đoán, kiểm toán, REPL thường trú; sẵn sàng bàn giao

Bài học

- Lỗi của Lean là tín hiệu rẻ và giá trị nhất
- Kiểm toán ngữ nghĩa là bắt buộc
- Verifier là tài nguyên cần lập lịch

Bàn giao, tái lập

- Cổng Nhóm 5, repaired-v1 cho Nhóm 7/8
- Docker · 121 test · notebook
- Log phát lại, $0

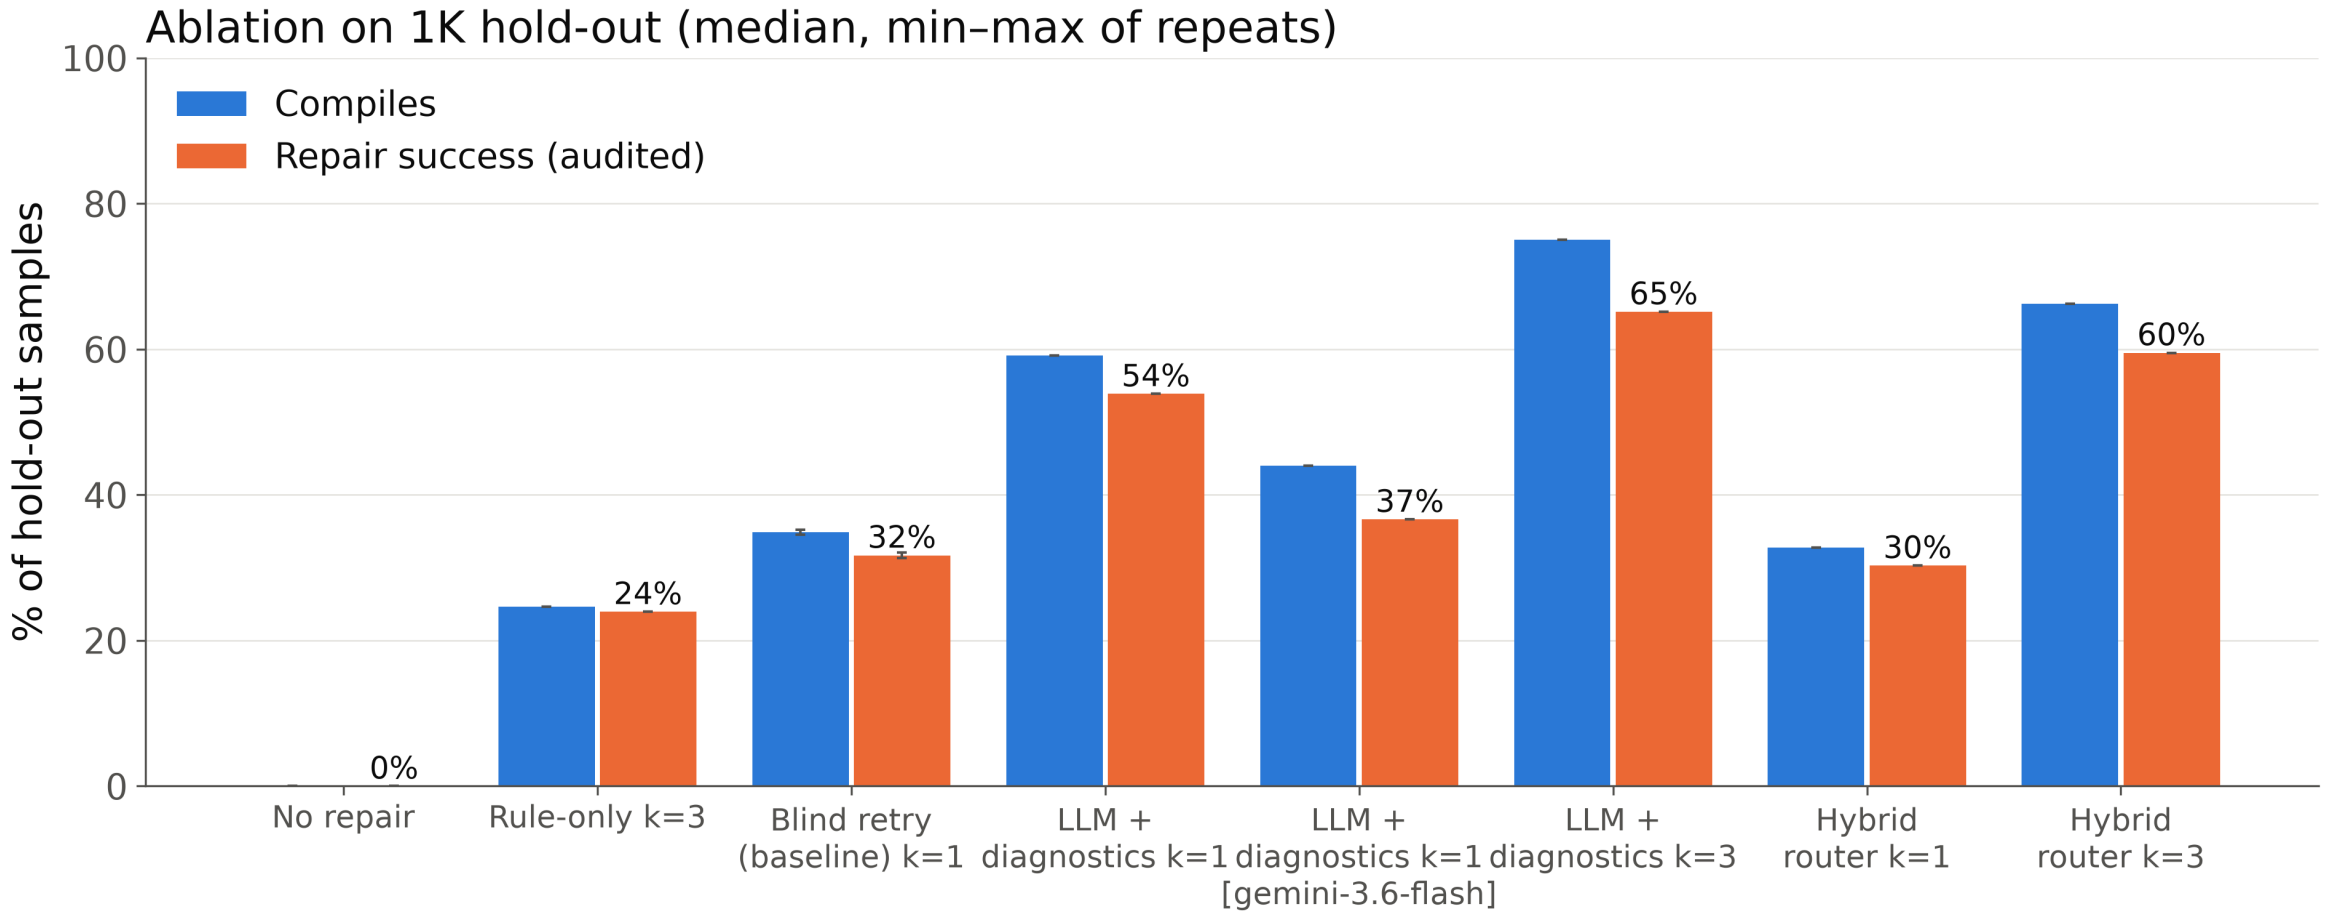
Hướng phát triển

- Dữ liệu thật của Nhóm 5
- Model chuyên Lean trên GPU
- Worker phân tán, hàng đợi Redis

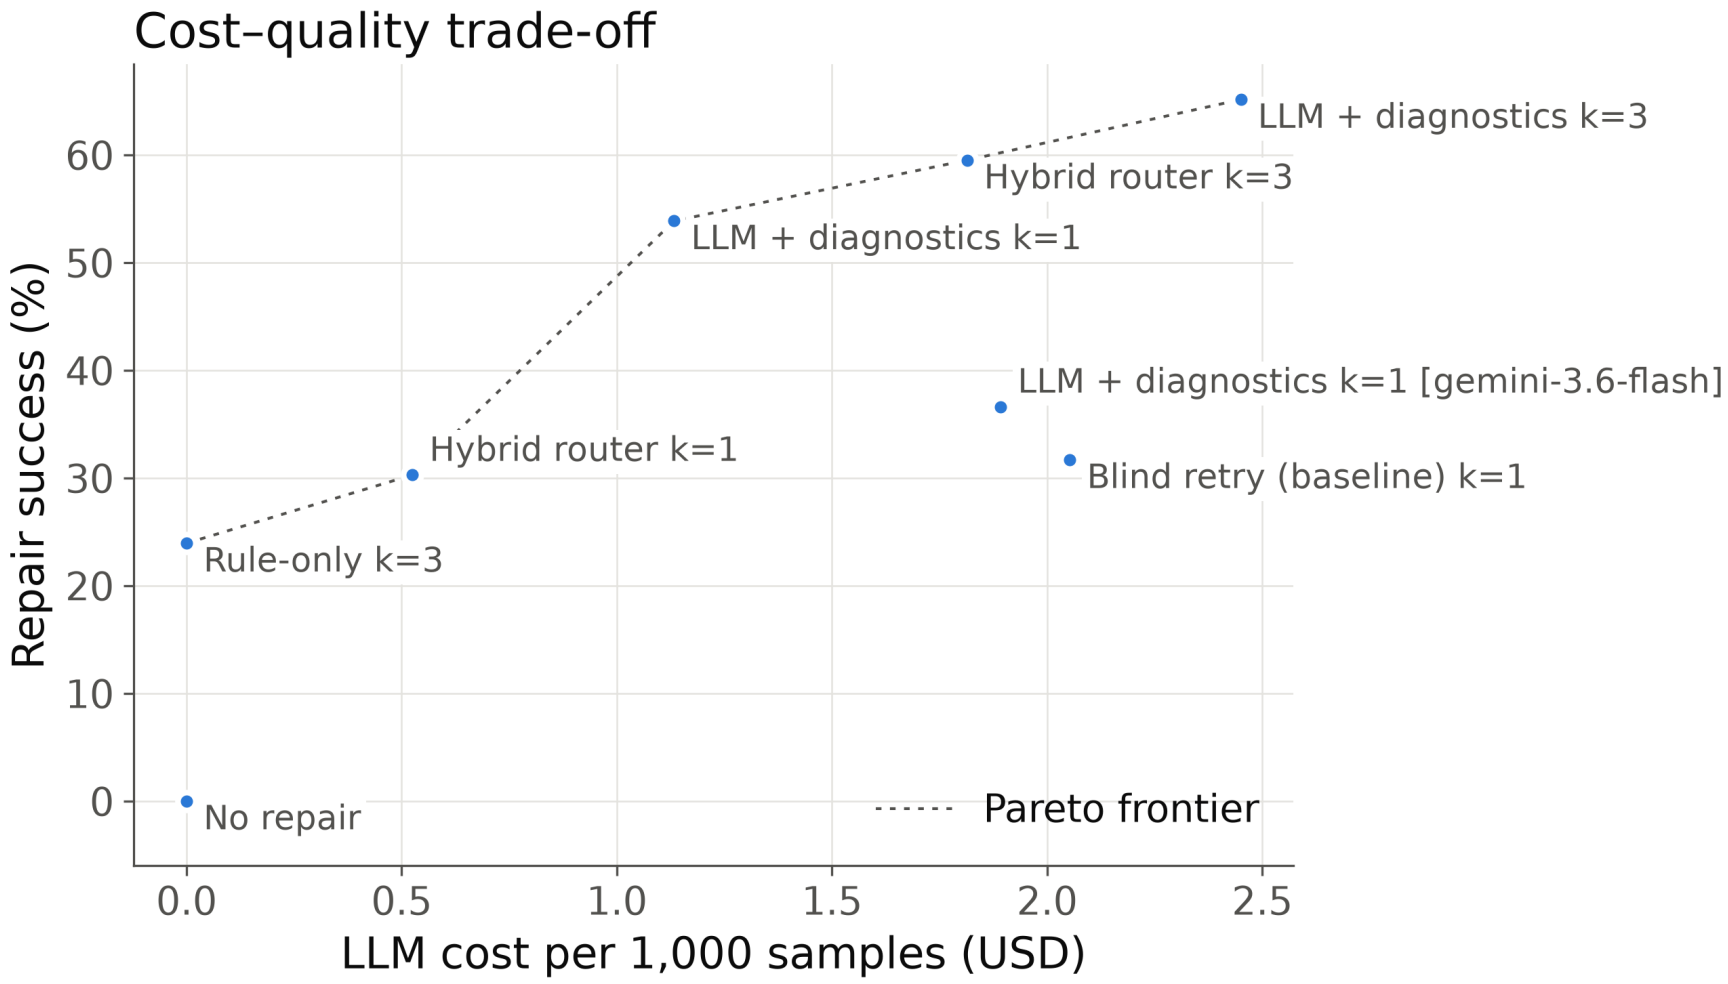
Cảm ơn cô và các bạn · Hỏi đáp

Thành viên	Mảng trả lời chính
Đào Văn Tâm	Câu hỏi nghiên cứu, đánh giá, chi phí
Trần Quang Đức Dũng	Hàng đợi Redis, worker pool, REPL, mở rộng
Lâm Thành Trung	Luật sửa, độ chính xác từng luật
Nguyễn Xuân Tùng	LLM: blind vs chẩn đoán, prompt, chọn model
Khamsing OUTHAIHUENG	Parser, taxonomy, kiểm toán
Mekdala Nounou	Dataset, chia tập, data card

Phụ lục P1 · RQ2: thử 3 lần đạt 65,1%, gấp đôi baseline



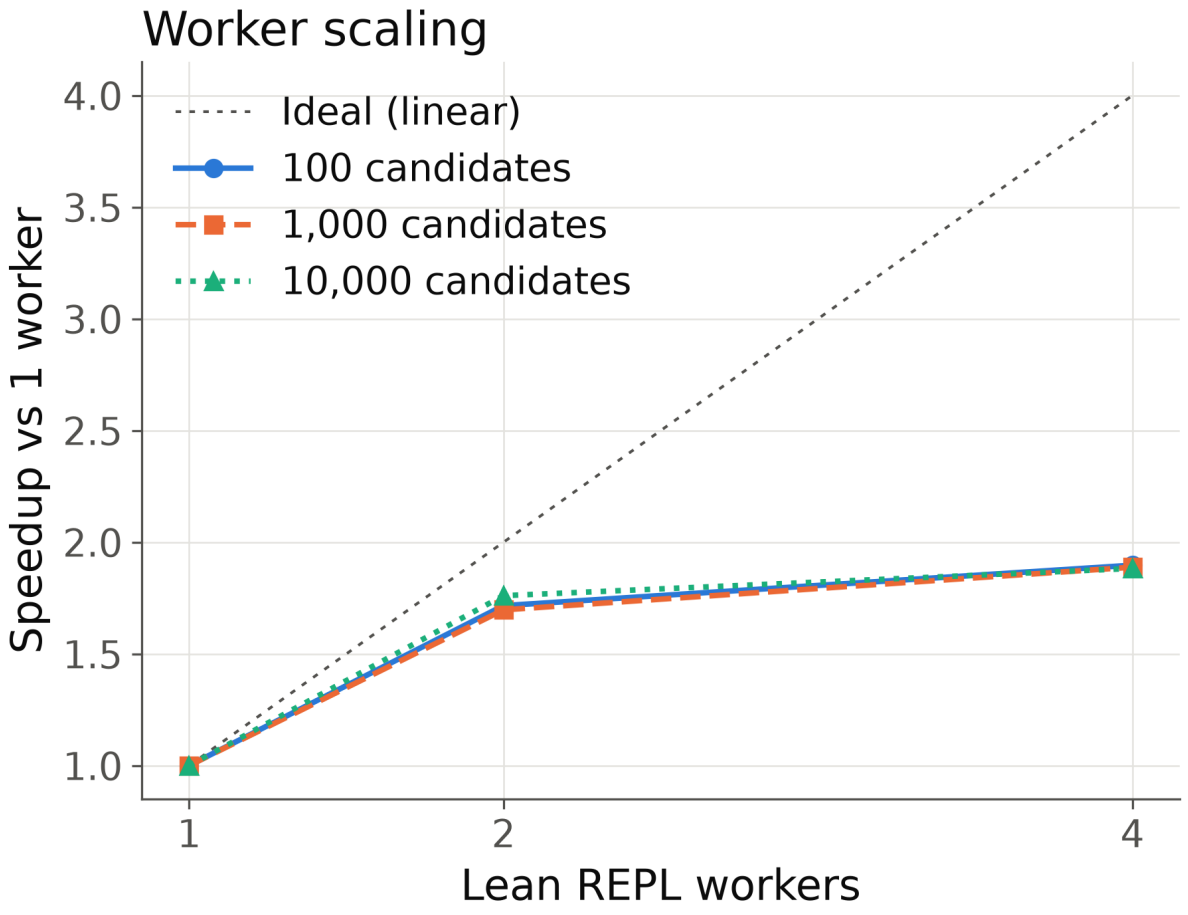
Phụ lục P2 · Chẩn đoán nằm trên biên Pareto chi phí và chất lượng



Đọc biểu đồ

- $0: luật 23,9%
- $1,13: 53,9%
- $2,45: 65,1%
- Blind $2,05: 31,7%

Phụ lục P3 · RQ3: REPL nhanh 3–4 bậc, 4 worker chỉ 1,88× vì nghẽn CPU



3 ms · 23 ms

P50 · P95 với REPL, nguội 63–107 s

1,52 → 2,86

mẫu/s ở 10K, từ 1 lên 4 worker

3,1 → 6,5 s

P95 thời gian phục vụ, 1 lên 4 worker